

Université Sidi Mohamed Ben Abdellah

Faculté des Sciences Dhar El Mahraz – Fès

Département d'Informatique

EXPLORER L'IA ET L'APPRENTISSAGE FÉDÉRÉ

Rapport du Projet :

Prédiction de la Qualité de l'Air
dans les Villes Marocaines

Réalisé par : LAMRINI Houda
LEMIRANI Amira

Filière : Master BDSI

. Table des matières

1	Introduction et présentation du projet	2
2	Étape 1 – Collecte des données	2
2.1	Connexion à l'API OpenWeatherMap	2
2.2	Collecte des données météorologiques	2
2.3	Collecte des données de qualité de l'air	3
2.4	Collecte automatisée et sauvegarde	3
2.5	Résultat de la collecte	3
3	Étape 2 – Préparation des données	4
3.1	Chargement et exploration initiale	4
3.2	Nettoyage des données	4
3.3	Analyse de la variable cible : PM2.5	4
3.4	Extraction de features temporelles	4
3.5	Encodage des variables catégorielles	5
3.6	Sélection des features et corrélation avec la cible	5
3.7	Normalisation des données	5
3.8	Sauvegarde du dataset propre	5
4	Étape 3 – Construction et évaluation des modèles	6
4.1	Chargement du dataset et séparation Train/Test	6
4.2	Modèle 1 – Régression Linéaire	6
4.3	Modèle 2 – Random Forest	6
4.4	Comparaison des deux modèles	6
4.5	Prédictions vs valeurs réelles	6
4.6	Importance des features	7
4.7	Analyse des erreurs	7
4.8	Résultats et conclusion de l'étape 3	8
5	Étape 4 (Bonus) – Apprentissage Fédéré : Version Manuelle	9
5.1	Principe et objectif	9
5.2	Partition des données par ville	9
5.3	Modèle centralisé de référence	9
5.4	Simulation du Federated Learning – Algorithme FedAvg	9
5.5	Convergence du modèle fédéré	10
5.6	Comparaison : modèles locaux, fédéré et centralisé	10
5.7	Analyse et conclusion du Federated Learning	11
6	Étape 5 (Bonus) – Apprentissage Fédéré : Version Flower	12
6.1	Pourquoi une seconde implémentation?	12
6.2	Architecture Flower	12
6.3	Convergence du modèle Flower FedAvg	12
6.4	Comparaison Flower FedAvg vs modèle centralisé	13
6.5	Comparaison entre les deux implémentations du Federated Learning	13
	Conclusion générale	13

1. Introduction et présentation du projet

Ce projet a pour objectif de construire des modèles de **Machine Learning** permettant de prédire la qualité de l'air (concentration de **PM2.5**) dans plusieurs villes marocaines, à partir de données réelles collectées via une API publique. Le travail est organisé en quatre étapes : la collecte des données, leur préparation, la construction de modèles centralisés, puis une étape bonus explorant les bases de l'**apprentissage fédéré** (Federated Learning).

Quatre villes marocaines ont été choisies pour ce travail : **Casablanca**, **Rabat**, **Marrakech** et **Fès**. Les données utilisées proviennent de l'API **OpenWeatherMap**, qui fournit à la fois des données météorologiques (température, humidité, pression, vent, etc.) et des données de qualité de l'air (AQI, PM2.5, PM10, NO2, O3, CO, SO2).

L'ensemble du travail a été réalisé sous forme de notebooks Jupyter, organisés de façon modulaire et reproductible :

- 01_collecte.ipynb – Collecte des données via l'API
- 02_preparation.ipynb – Nettoyage et préparation du dataset
- 03_modeles.ipynb – Construction et évaluation des modèles centralisés
- 04_federe.ipynb – Simulation manuelle du Federated Learning (FedAvg codé à la main)
- 04_federe_flower.ipynb – Federated Learning implémenté avec la librairie **Flower** (flwr)

Deux implémentations du Federated Learning ont ainsi été réalisées : une version pédagogique où l'algorithme FedAvg est codé entièrement à la main, et une version utilisant le framework professionnel **Flower**, afin de comparer une implémentation "from scratch" à une implémentation standard de l'industrie.

2. Étape 1 – Collecte des données

2.1. Connexion à l'API OpenWeatherMap

Description : Deux points d'accès (endpoints) de l'API OpenWeatherMap ont été utilisés : un pour les données météorologiques (/data/2.5/weather) et un pour les données de qualité de l'air (/data/2.5/air_pollution). Une clé API personnelle a été configurée pour authentifier les requêtes.

Listing 1 – Définition des URLs et des villes ciblées

```
1 URL_METEO = "https://api.openweathermap.org/data/2.5/weather"
2 URL_AIR    = "http://api.openweathermap.org/data/2.5/
   air_pollution"
3
4 VILLES = ["Casablanca", "Rabat", "Marrakech", "Fes"]
```

2.2. Collecte des données météorologiques

Description : Une fonction `collecter_meteo(ville)` a été développée pour interroger l'API et extraire les variables météorologiques pertinentes : température, tempé-

rature ressentie, humidité, pression, vitesse et direction du vent, nébulosité, visibilité, ainsi que la description textuelle de la météo.

2.3. Collecte des données de qualité de l'air

Description : La fonction `collecter_air(ville, latitude, longitude)` interroge le second endpoint de l'API à partir des coordonnées géographiques de la ville, et récupère l'indice de qualité de l'air (AQI) ainsi que les concentrations des polluants : PM2.5, PM10, NO2, O3, CO et SO2.

2.4. Collecte automatisée et sauvegarde

Description : Une fonction globale `collecter_toutes_les_villes()` fusionne, pour chaque ville, les données météo et les données de qualité de l'air en une seule ligne, puis sauvegarde l'ensemble dans un fichier CSV (`data_raw.csv`). Une boucle de collecte automatique a également été mise en place pour répéter la collecte à intervalles réguliers (toutes les heures), afin d'obtenir des données sur plusieurs jours et ainsi enrichir le dataset avec de la variabilité temporelle.

2.5. Résultat de la collecte

Description : Le fichier `data_raw.csv` final regroupe l'ensemble des relevés collectés pour les quatre villes, avec un horodatage (timestamp) pour chaque ligne, permettant de suivre l'évolution de la qualité de l'air dans le temps.

3. Étape 2 – Préparation des données

3.1. Chargement et exploration initiale


Description : Le fichier `data_raw.csv` est chargé, puis une première exploration est effectuée (types des colonnes, statistiques descriptives) afin de comprendre la structure des données avant tout traitement.

3.2. Nettoyage des données

Description : Vérification et suppression des doublons, ainsi que des valeurs manquantes éventuelles, afin de garantir la qualité du dataset final.


3.3. Analyse de la variable cible : PM2.5

Description : La distribution de la variable cible PM2.5 est analysée globalement, ainsi que sa répartition par ville (boîtes à moustaches), afin de détecter d'éventuelles valeurs aberrantes ou des écarts significatifs entre villes.



3.4. Extraction de features temporelles

Description : À partir de la colonne `timestamp`, trois nouvelles variables ont été créées : l'heure de la journée, le jour de la semaine et le jour du mois. Ces variables permettent de capturer d'éventuels effets cycliques (par exemple, une pollution plus forte aux heures de pointe).




3.5. Encodage des variables catégorielles

Description : Les variables catégorielles `ville` et `description_meteo` sont encodées numériquement à l'aide d'un `LabelEncoder`, afin de pouvoir être exploitées par les modèles de Machine Learning.

3.6. Sélection des features et corrélation avec la cible

Description : Les colonnes non pertinentes (identifiants, texte brut, variable cible) sont exclues de l'ensemble des features. Une matrice de corrélation est ensuite calculée entre chaque feature retenue et la variable cible PM2.5, afin d'identifier les variables les plus influentes.



3.7. Normalisation des données

Description : Les features numériques sont normalisées à l'aide d'un `StandardScaler` ce qui est particulièrement utile pour les modèles linéaires.

3.8. Sauvegarde du dataset propre

Description : Le dataset final, prêt pour la modélisation, est sauvegardé dans le fichier `data_clean.csv`. Il contient les features normalisées, la variable cible `pm2_5`, ainsi que la colonne `ville`.

4. Étape 3 – Construction et évaluation des modèles

4.1. Chargement du dataset et séparation Train/Test

Description : Le dataset propre `data_clean.csv` est chargé, puis séparé en un ensemble d'entraînement (80%) et un ensemble de test (20%), à l'aide de `train_test_split` avec une graine aléatoire fixe (`random_state=42`) afin de garantir la reproductibilité des résultats.

4.2. Modèle 1 – Régression Linéaire


Description : Un premier modèle, simple et interprétable, est entraîné : la **Régression Linéaire**. Il sert de référence de base pour évaluer la complexité nécessaire du problème.

4.3. Modèle 2 – Random Forest

Description : Un second modèle, plus complexe, est entraîné : une **forêt aléatoire** (`RandomForestRegressor`, 100 arbres, profondeur maximale de 10). Ce type de modèle permet de capturer des relations non linéaires entre les features et la cible.


4.4. Comparaison des deux modèles

Description : Les deux modèles sont évalués sur l'ensemble de test à l'aide de trois métriques de régression : le **MAE** (erreur absolue moyenne), le **RMSE** (racine de l'erreur quadratique moyenne) et le **R²** (coefficient de détermination).




4.5. Prédictions vs valeurs réelles

Description : Pour chaque modèle, les valeurs prédites sont comparées graphiquement aux valeurs réelles de PM2.5 sur l'ensemble de test, afin d'évaluer visuellement la qualité des prédictions par rapport à la droite de prédiction parfaite ($y = x$).




4.6. Importance des features

Description : L'importance de chaque feature dans les prédictions du modèle Random Forest est extraite et visualisée, ce qui permet d'identifier les variables les plus déterminantes pour prédire la qualité de l'air.



4.7. Analyse des erreurs

Description : La distribution des erreurs de prédiction (valeur réelle moins valeur prédite) est analysée pour les deux modèles, afin de vérifier que les erreurs sont globalement centrées autour de zéro et ne présentent pas de biais systématique.



4.8. Résultats et conclusion de l'étape 3

Résultats obtenus : Les deux modèles ont été comparés à l'aide des métriques MAE, RMSE et R^2 . Le modèle le plus performant a été retenu comme référence pour la comparaison avec l'approche fédérée de l'étape suivante.

Interprétation : Le R^2 obtenu indique le pourcentage de variance de $\text{PM}_{2.5}$ expliqué par le modèle ; le MAE indique l'erreur moyenne, en $\mu\text{g}/\text{m}^3$, commise par le modèle sur ses prédictions.


5. Étape 4 (Bonus) – Apprentissage Fédéré : Version Manuelle

5.1. Principe et objectif

Description : Dans cette étape bonus, l'objectif est de simuler un scénario d'apprentissage fédéré, dans lequel chaque ville marocaine joue le rôle d'un **client fédéré** qui conserve ses propres données localement. Aucune donnée brute n'est jamais partagée entre les villes ni envoyée à un serveur central : seuls les paramètres des modèles locaux (coefficients et biais) sont échangés et agrégés. Cette première implémentation (04_federe.ipynb) code l'intégralité de l'algorithme **FedAvg** manuellement, sans librairie de Federated Learning, afin de bien comprendre la mécanique sous-jacente.

5.2. Partition des données par ville

Description : Le dataset propre est partitionné par ville. Chaque ville constitue un client indépendant disposant de son propre sous-ensemble d'entraînement, tandis qu'un ensemble de test global (identique à celui de l'étape 3, même `random_state`) est conservé pour évaluer équitablement le modèle global à chaque round.



5.3. Modèle centralisé de référence

Description : Un modèle de Régression Linéaire centralisé est entraîné sur l'ensemble du jeu d'entraînement global (toutes les villes réunies), afin de disposer d'une référence de performance maximale à comparer avec le modèle fédéré.

5.4. Simulation du Federated Learning – Algorithme FedAvg

Description : Un modèle global est initialisé avec des paramètres nuls (coefficients et biais à zéro). À chaque round de communication :

1. le modèle global est envoyé à chaque ville (client) ;
2. chaque ville entraîne localement un modèle `SGDRegressor` (régression par descente de gradient stochastique, compatible avec un apprentissage incrémental) sur ses propres données, en partant des paramètres globaux reçus (warm-start) ;
3. chaque ville renvoie ses paramètres locaux mis à jour ;

- le serveur agrège ces paramètres par une **moyenne pondérée** en fonction du nombre d'échantillons de chaque ville (algorithme **FedAvg** – Federated Averaging), puis met à jour le modèle global.

Cette procédure est répétée sur plusieurs rounds, et la performance du modèle global est évaluée à chaque round sur l'ensemble de test global.

Listing 2 – Agrégation FedAvg – moyenne pondérée des paramètres


```

1 n_total = sum(local_sizes)
2 global_coef = sum(c * (s / n_total) for c, s in zip(
    local_coefs, local_sizes))
3 global_intercept = sum(b * (s / n_total) for b, s in zip(
    local_intercepts, local_sizes))

```


5.5. Convergence du modèle fédéré

Description : L'évolution des métriques (MAE, RMSE, R^2) du modèle global est suivie à chaque round, afin d'observer la convergence progressive du modèle fédéré vers une performance proche du modèle centralisé.



5.6. Comparaison : modèles locaux, fédéré et centralisé

Description : Les performances de modèles entraînés uniquement sur les données locales de chaque ville (sans collaboration) sont comparées à celles du modèle fédéré final et du modèle centralisé, afin de mettre en évidence l'apport de la collaboration fédérée par rapport à un entraînement isolé par ville.



5.7. Analyse et conclusion du Federated Learning

Avantages observés :

- Les données brutes de chaque ville ne quittent jamais leur environnement local – seuls les paramètres du modèle sont communiqués, ce qui préserve la confidentialité des données.
- La performance du modèle global s'améliore progressivement à chaque round de communication, démontrant la convergence de l'algorithme FedAvg.
- Cette approche est applicable à des contextes réels où le partage centralisé des données est impossible ou indésirable (hôpitaux, capteurs urbains répartis, appareils mobiles).

Limites observées :

- La performance du modèle fédéré reste légèrement inférieure à celle du modèle centralisé, ce qui constitue un compromis acceptable au regard du gain en confidentialité.
- La convergence nécessite plusieurs rounds de communication.
- La performance dépend de la quantité de données disponible localement pour chaque client (ville).

6. Étape 5 (Bonus) – Apprentissage Fédéré : Version Flower

6.1. Pourquoi une seconde implémentation ?

Description : En complément de la version manuelle, une seconde implémentation du Federated Learning a été réalisée à l'aide de la librairie **Flower (flwr)**, un framework open-source standard pour le Federated Learning. Cette version (04_federe_flower.ipynb) permet de comparer l'algorithme codé à la main avec une implémentation professionnelle, plus robuste et plus proche de ce qui est utilisé en production.

6.2. Architecture Flower

Description : Chaque ville est implémentée comme un client Flower héritant de `fl.client.NumPyClient`, avec trois méthodes principales :

- `get_parameters()` – envoie les paramètres actuels du modèle local au serveur ;
- `fit()` – reçoit les paramètres globaux, entraîne le modèle local (`SGDRegressor`) sur les données de la ville, puis renvoie les paramètres mis à jour ;
- `evaluate()` – évalue le modèle global reçu sur l'ensemble de test.


Le serveur utilise la stratégie officielle `fl.server.strategy.FedAvg`, et l'ensemble de la simulation est lancé via `fl.simulation.start_simulation()`, qui exécute tous les clients en parallèle dans le même processus.

Listing 3 – Stratégie FedAvg officielle de Flower

```
1 strategy = fl.server.strategy.FedAvg(  
2     fraction_fit=1.0,  
3     fraction_evaluate=1.0,  
4     min_fit_clients=len(VILLES),  
5     min_evaluate_clients=len(VILLES),  
6     min_available_clients=len(VILLES),  
7     evaluate_metrics_aggregation_fn=aggregate_metrics,  
8 )
```


6.3. Convergence du modèle Flower FedAvg

Description : L'évolution des métriques (MAE, RMSE, R^2) du modèle global est suivie à chaque round de communication, afin d'observer la convergence du modèle fédéré géré par Flower.



6.4. Comparaison Flower FedAvg vs modèle centralisé

Description : Les performances finales du modèle fédéré obtenu avec Flower sont comparées à celles du modèle centralisé de référence (Régression Linéaire entraînée sur l'ensemble des données réunies).



6.5. Comparaison entre les deux implémentations du Federated Learning

Analyse : Les deux implémentations (manuelle et Flower) reposent sur le même principe – l'algorithme FedAvg – mais différent dans leur mise en œuvre :

TABLE 1 – Comparaison entre la version manuelle et la version Flower

Aspect	Version manuelle	Version Flower
Agrégation FedAvg	Codée à la main	Algorithme officiel Flower
Architecture client	Boucle Python simple	Classe NumPyClient
Scalabilité	4 clients fixes	N clients dynamiques
Proximité production	Pédagogique	Production-ready

Ce projet a permis de mettre en œuvre un pipeline complet de Machine Learning appliqué à un problème réel et concret : la prédiction de la qualité de l'air dans plusieurs villes marocaines. En partant de la collecte de données réelles via l'API OpenWeather-Map, en passant par un nettoyage et une préparation rigoureuse des données, jusqu'à l'entraînement et la comparaison de plusieurs modèles de régression, ce travail illustre l'ensemble de la chaîne classique d'un projet de data science.

L'étape bonus consacrée au **Federated Learning** a permis d'explorer une approche alternative et plus respectueuse de la confidentialité des données, à travers deux implémentations complémentaires : une version où l'algorithme **FedAvg** est codé manuellement, permettant de comprendre en détail sa mécanique, et une version utilisant la librairie professionnelle **Flower**, plus robuste et plus proche d'un contexte de production. Les résultats obtenus avec les deux approches montrent qu'il est possible d'obtenir des performances proches d'une approche centralisée, sans jamais avoir à centraliser les données sensibles des différentes villes – une propriété particulièrement utile dans des contextes réels où la confidentialité des données est une contrainte forte.

Rapport réalisé par **LAMRINI Houda** et **LEMRANI Amira**
Master BDSI – FSDM, 2025/2026